zxcvg的专栏

■ 目录视图

늘 摘要视图



个人资料



访问: 130124次

积分: 1420

等级: BLOC > 4

排名: 第18027名

原创: 30篇 转载: 29篇 译文: 0篇 评论: 31条

文章搜索

文章分类

Eclipse (0)

struts+hibernate+spring (6)

swt/Jface (1)

EJB (3)

设计模式 (2)

Oracle (4)

SVN (2)

java (22)

C (0)

敏捷 (3) db (3)

PHP (2)

clojure (1)

storm (2)

kafka (2)

flume (1)

linux (1)

arduin (0)

arduino (1)

文章存档

2015年11月 (1)

Unity3D中基于订阅者模式实现事件机制 云计算行业圆桌论坛 【征文】Hadoop十周年特别策划——我与Hadoop不得不说的

Flume-ng+Kafka+storm的学习笔记

2014-01-21 11:33

41714人阅读

评论(4) 收藏 举报

₩分类:

storm (1) - kafka (1) - flume

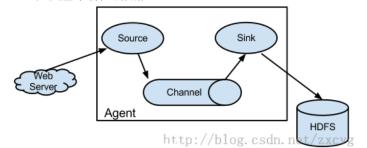
■版权声明:本文为博主原创文章,未经博主允许不得转载。

吐个槽: 在word文档中写好的 包括图片 在csdn粘贴过来后 图片必须重新上传 不爽啊!! Flume-ng+Kafka+storm的学习笔记

Flume-ng

Flume是一个分布式、可靠、和高可用的海量日志采集、聚合和传输的系统。

Flume的文档可以看http://flume.apache.org/FlumeUserGuide.html 官方的英文文档 介绍的比较全面。 不过这里写写自己的见解



这个是flume的架构图

从上图可以看到几个名

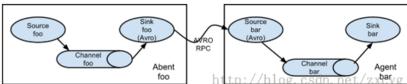
Agent: 一个Agent包含Source、Channel、Sink和其他的组件。Flume就是一个或多个Agent构成的。

Source: 数据源。简单的说就是agent获取数据的入口。

Channel: 管道。数据流通和存储的通道。一个source必须至少和一个channel关联。

Sink: 用来接收channel传输的数据并将之传送到指定的地方。传送成功后数据从channel中删除。

Flume具有高可扩展性 可随意组合:



注意 source是接收源 sink是发送源

2015年10月 (1) 2015年08月 (1) 2014年07月 (1) 2014年03月 (2) 展开

(1714)

阅读排行

SpringMVC

Flume-ng+Kafka+stormf (41661) order by用法 (23915)kafka Failed to send mes (10570)Java软件低级错误(十 3 (3460) 新浪微博图床架构解析 (3054)Java软件低级错误(十 / (2732) openfire性能 (2683)Java软件低级错误(五) (1987) Java软件低级错误(六) (1864)

评论排行	
kafka Failed to send mes	(21)
order by用法	(4)
Flume-ng+Kafka+storm∄	(4)
storm 例子 记录	(2)
SpringMVC	(1)
oracle前10条记录取法(rc	(0)
EJB会话Bean	(0)
EJB基础JBoss服务器	(0)
arduino开发板在MAC Ost	(0)
重新梳理三大框架strı	(0)

推荐文章

- * HDFS如何检测并删除多余副本 块
- * Project Perfect让Swift在服务器 端跑起来一让Perfect更Rails (五)
- *数据库性能优化之SQL语句优化
- * Animation动画详解(七)-ObjectAnimator基本使用
- * 机器学习系列(7)_机器学习路线 图 (附资料)
- *一个程序员的Java和C, C++学 习之路(整理)

最新评论

Flume-ng+Kafka+storm的学习笔 zengqingchun: JedisUtils 这个类 是自己写的吧 查api没有这个类

kafka Failed to send messages a 民工小勇: 既然有两种方式都可以 搞定,那到底哪种方式是推荐的呢?

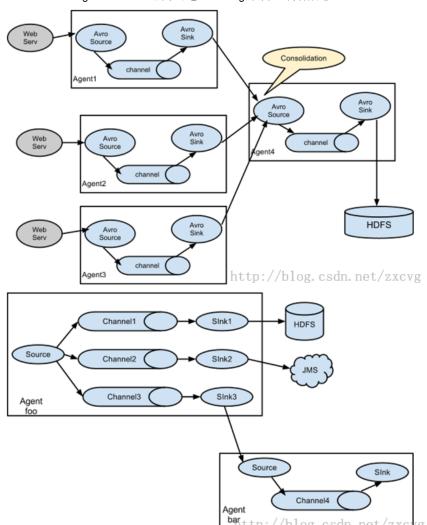
Flume-ng+Kafka+storm的学习笔 u010409394: 前辈,本文中的"Worker: 处理逻辑的进程,在 其中运行着多个Task,每个task 是一组spou...

order by用法

小颜Kevin: 谢谢 初学者,帮了我

kafka Failed to send messages a tyzl1988: 改过后在kafka服务器 上地运行producer的话./kafkaconsole-producer.

kafka Failed to send messages a



上图是一个source将数据发给3个channel 其中的sink2将数据发给JMS, sink3将数据发给另一个source。 总的来说flume的扩展性非常高 根据需要可随意组合。

现在在说说一个概念叫Event:

Event是flume的数据传输的基本单元。Flume本质上是将数据作为一个event从源头传到结尾。是由可选的 Headers和载有数据的一个byte array构成。

代码结构:

```
[java] view plain copy print ?
* Basic representation of a data object inFlume.
public interface Event{
 /**
  \ensuremath{^{*}} Returns a map of name-value
pairs describing the data stored in the body.
  */
 public Map<String, String> getHeaders();
 /**
  * Set the event headers
  \ensuremath{^*} @param headersMap of headers to replace the current headers.
 public void setHeaders(Map<String, String> headers):
  * Returns the raw byte array of the datacontained in this event.
  */
 public byte[] getBody();
  * Sets the raw byte array of the datacontained in this event.
  * @param body Thedata.
  public void setBody(byte[] body);
```

tyzl1988: @poorzerg:成功了,感谢! 改成host.name = 192.18.0.69192.18.0...

kafka Failed to send messages a sihuanyiyu: 我也遇到了一样的问 题。最后在运行producer 的机器 中的hosts文件下加入kafka serv...

kafka Failed to send messages a sihuanyiyu: 我也遇到了一样的问题。最后在运行producer 的机器中的hosts文件下加入kafka serv....

kafka Failed to send messages a poorzerg: 在kafka服务端的配置文件里,有一个host.name的配置,需要把值配置成ip。服务端是会把ho...

order by用法 snooppyy: 茅塞顿开 这个是网上找的flume channel ,source,sink的汇总

链接是http://abloz.com/2013/02/26/flume-channel-source-sink-summary.html

链接是http://abloz.com	n/2013/02/26/flume-channel-source-sink-summary.html	
Component	Туре	Description
Channel	memory	In-memory, fast, non-c
Channal	Ela	A channel for reading,
Channel	file	manipulating a file
Observati		JDBC-based, durable
Channel	jdbc	based)
		A durable channel imp
Channel	recoverablememory	the local file system fo
		Mainly for testing purp
Channel	org.apache.flume.channel.PseudoTxnMemoryChannel	production use.
Channel	(custom type as FQCN)	Your own Channel imp
Source	avro	Avro Netty RPC event
_		Execute a long-lived L
Source	exec	from stdout
Source	netcat	Netcat style TCP even
		Monotonically increme
Source	seq	generator event source
		Mainly for testing purp
		production use. Serve
		source of events wher
		same payload. The pa
Source	org.apache.flume.source.StressSource	number of bytes (spec
		defaults to 500) where
		signed value Byte.MA
		127).
Source	syslogtcp	SyslogTcpSource
Source	syslogudp	SyslogUDPSource
Source	org.apache.flume.source.avroLegacy.AvroLegacySource	AvroLegacySource
Source	org.apache.flume.source.thriftLegacy.ThriftLegacySource	ThriftLegacySource
Source	org.apache.flume.source.scribe.ScribeSource	ScribeSource
Source	(custom type as FQCN)	Your own Source impl
	(cases) ype ac a gary	Writes all events recei
0.1		support for rolling, buc
Sink	hdfs	append, and more)
		appena, and more)
Sink	org.apache.flume.sink.hbase.HBaseSink	A simple sink that read
SIIK	отд.араспелителянклиавел правевник	and writes them to HB
Sink	org.apache.flume.sink.hbase.AsyncHBaseSink	org.apache.flume.sink
Sink	logger	Log events at INFO le
SIIK	loggei	logging subsystem (log
		Sink that invokes a pre
Sink	avro	method for all events i
		with an avro source, fo
Sink	file_roll	RollingFileSink
Sink	irc	IRCSink
Sink	oull.	/dev/null for Flume – b
Sink	null	received
Sink	(custom type as FQCN)	Your own Sink impl.
ChannelSelector	replicating	ReplicatingChannelSe
ChannelSelector	multiplexing	MultiplexingChannelSe
ChannelSelector	(custom type)	Your own ChannelSel

	· ·	3	
	SinkProcessor	default	DefaultSinkProcessor
	SinkProcessor	failover	FailoverSinkProcessor
	SinkProcessor	load_balance	Provides the ability to
			multiple sinks.
	SinkProcessor	(custom type as FQCN)	Your own SinkProcess
	Interceptor\$Builder	host	HostInterceptor\$Builde
	Interceptor\$Builder	timestamp	TimestampInterceptor
	Interceptor\$Builder	static	StaticInterceptor\$Build
	Interceptor\$Builder	regex_filter	RegexFilteringIntercer
	Interceptor\$Builder	(custom type as FQCN)	Your own Interceptor\$
	EventSerializer\$Builder	text	Body Text Event Serializ
	EventSerializer\$Builder	avro_event	FlumeEventAvroEvent
	EventSerializer	org. apache. flume. sink. hbase. Simple Hbase Event Serializer	SimpleHbaseEventSe
	EventSerializer	org. a pache. flume. sink. hbase. Simple Async Hbase Event Serialize the sink of the sin	rSimpleAsyncHbaseEv
	EventSerializer	org. a pache. flume. sink. hbase. Regex Hbase Event Serializer	RegexHbaseEventSer
ŀ	HbaseEventSerializer	Custom implementation of serializer for HBaseSink.	Your own HbaseEvent
		(custom type as FQCN)	
AsyncHbaseEventSerialize	AsyncHhaseEventSerialize	Custom implementation of serializer for AsyncHbase sink.	Your own AsyncHbase
	(custom type as FQCN)	Tour Own Asynchibase	
		Custom implementation of serializer for all sinks except for	

EventSerializer\$Builder HBaseSink and AsyncHBaseSink. Your own EventSeriali

(custom type as FQCN)

下面介绍下kafka以及kafka和flume的整合

Kafka:

从这个链接抄了些内容下来http://dongxicheng.org/search-engine/kafka/

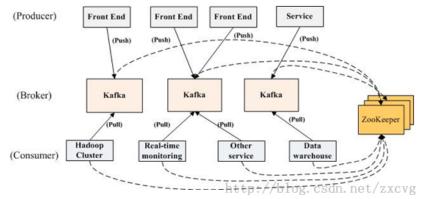
Kafka是Linkedin于2010年12月份开源的消息系统,它主要用于处理活跃的流式数据。活跃的流式数据在web网站应用中非常常见,这些数据包括网站的pv、用户访问了什么内容,搜索了什么内容等。 这些数据通常以日志的形式记录下来,然后每隔一段时间进行一次统计处理。

传统的日志分析系统提供了一种离线处理日志信息的可扩展方案,但若要进行实时处理,通常会有较大延迟。而现有的消(队列)系统能够很好的处理实时或者近似实时的应用,但未处理的数据通常不会写到磁盘上,这对于 Hadoop之类(一小时或者一天只处理一部分数据)的离线应用而言,可能存在问题。Kafka正是为了解决以上问题而设计的,它能够很好地离线和在线应用。

2、 设计目标

- (1)数据在磁盘上存取代价为O(1)。一般数据在磁盘上是使用BTree存储的,存取代价为O(Ign)。
- (2) 高吞吐率。即使在普通的节点上每秒钟也能处理成百上千的message。
- (3) 显式分布式,即所有的producer、broker和consumer都会有多个,均为分布式的。
- (4) 支持数据并行加载到Hadoop中。

3、 KafKa部署结构



kafka是显式分布式架构,producer、broker(Kafka)和consumer都可以有多个。Kafka的作用类似于缓存,即 活跃的数据和离线处理系统之间的缓存。几个基本概念:

(1) message (消息) 是通信的基本单位,每个producer可以向一个topic (主题) 发布一些消息。如果 consumer订阅了这个主题,那么新发布的消息就会广播给这些consumer。

(2) Kafka是显式分布式的,多个producer、consumer和broker可以运行在一个大的集群上,作为一个逻辑整体对外提供服务。对于consumer,多个consumer可以组成一个group,这个message只能传输给某个group中的某一个consumer.

数据从producer推送到broker,接着consumer在从broker上拉取数据。Zookeeper是一个分布式服务框架 用来解决分布式应用中的数据管理问题等。

在kafka中 有几个重要概念producer生产者 consumer 消费者 topic 主题。

我们来实际开发一个简单的生产者消费者的例子。 生产者:

```
[java] view plain copy print ?

public classProducerTest {

public static void main(String[] args) {

    Properties props = newProperties();

    props.setProperty("metadata.broker.list","xx.xx.xx.xx:9092");

    props.setProperty("serializer.class","kafka.serializer.StringEncoder");

    props.put("request.required.acks","1");

    ProducerConfigconfig = new ProducerConfig(props);

    Producer<String, String> producer = newProducer<String, String>(config);

    KeyedMessage<String, String> data = newKeyedMessage<String, String>

    ("kafka","test-kafka");

    try {

        producer.send(data);

        } catch (Exception e) {

            e.printStackTrace();

        }

        producer.close();

}
```

上面的代码中的xx.xx.xx是kafka server的地址.

上面代码的意思就是向主题 kafka中同步(不配置的话 默认是同步发射)发送了一个信息 是test-kafka. 下面来看看消费者:

```
[java] view plain copy print ?
public classConsumerTest extends Thread {
   private finalConsumerConnector consumer;
   private final String topic;
   public static voidmain(String[] args) {
   publicConsumerTest(String topic) {
       this.topic =topic;
   private staticConsumerConfig createConsumerConfig() {
       props.put("zookeeper.connect","xx.xx.xx.xx:2181");
       props.put("group.id", "0");
       props.put("zookeeper.session.timeout.ms","10000");
        props.put("zookeeper.sync.time.ms", "200");
        props.put("auto.commit.interval.ms", "1000");
       return newConsumerConfig(props);
   public void run(){
       Map<String,Integer> topickMap = new HashMap<String, Integer>();
       topickMap.put(topic, 1);
        Map<String, List<KafkaStream<bpte[],byte[]>>> streamMap =consumer.createMessageStream
        KafkaStream<byte[],byte[]>stream = streamMap.get(topic).get(0);
```

上面的代码就是负责接收生产者发送过来的消息 测试的时候先开启消费者 然后再运行生产者即可看到效果。接下来 我们将flume 和kafka进行整合:

在flume的source数据源接收到数据后 通过管道 到达sink,我们需要写一个kafkaSink 来将sink从channel接收的数据作为kafka的生产者 将数据 发送给消费者。

具体代码:

```
[java] view plain copy print ?
 public class KafkaSink extends AbstractSinkimplementsConfigurable {
     private static final Log logger = LogFactory.getLog(KafkaSink.class);
     private Stringtopic;
     private Producer<String, String>producer;
     @Override
     public Status process()throwsEventDeliveryException {
        Transaction tx =channel.getTransaction();
                if(e ==null) {
                        return Status.BACKOFF;
                KeyedMessage<String,String> data = new KeyedMessage<String, String>
(topic,newString(e.getBody()));
                logger.info("Message: {}"+new String( e.getBody()));
                return Status.READY;
        } catch(Exceptione) {
          logger.error("KafkaSinkException:{}",e);
               return Status.BACKOFF;
        } finally {
     public void configure(Context context) {
              props.setProperty("metadata.broker.list","xx.xx.xx:9092");
           props.setProperty("producer.type", "async");
           props.setProperty("batch.num.messages", "1");
             props.put("request.required.acks","1");
             ProducerConfigconfig = new ProducerConfig(props);
             producer = newProducer<String, String>(config);
```

将此文件打成jar包 传到flume的lib下面 如果你也用的是maven的话 需要用到assembly 将依赖的jar包一起打包进去。

在flume的配置是如下:

```
[plain] view plain copy print ?

agent1.sources = source1
agent1.sinks = sink1
agent1.channels = channel1

4.

b. # Describe/configuresource1
agent1.sources.source1.type= avro
agent1.sources.source1.bind= localhost
agent1.sources.source1.port= 44444

# Describe sink1
agent1.sinks.sink1.type= xx.xx.xx.KafkaSink(这是类的路径地址)

# Use a channel whichbuffers events in memory
agent1.channels.channel1.type= memory
agent1.channels.channel1.transactionCapactiy= 100

agent1.channels.channel1.transactionCapactiy= 100

# Bind the source andsink to the channel
agent1.sources.source1.channels= channel1
agent1.sinks.sink1.channel= channel1
```

测试的话是avro的方式传送数据的 可以这样测试

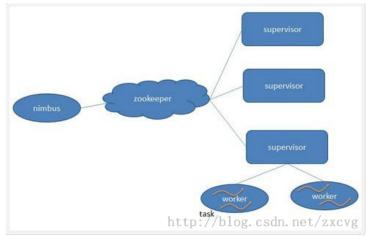
bin/flume-ng avro-client--conf conf -H localhost -p 44444 -F/data/flumetmp/a /data/flumetmp/a 这个为文件的地址.

测试的时候在本地一定要把上面写的消费者程序打开以便接收数据测试是否成功。接下来我们介绍下storm然后将kafka的消费者和storm进行整合:

Storm:

Storm是一个分布式的实时消息处理系统。

Storm各个组件之间的关系:



Storm集群主要由一个主节点和一群工作节点(worker node)组成,通过 Zookeeper进行协调。 主节点:主节点通常运行一个后台程序—— Nimbus,用于响应分布在集群中的节点,分配任务和监测故障。 工作节点: Supervisor,负责接受nimbus分配的任务,启动和停止属于自己管理的worker进程。Nimbus和 Supervisor之间的协调由zookeeper完成。

Worker: 处理逻辑的进程,在其中运行着多个Task,每个task是一组spout/blots的组合。

Topology:是storm的实时应用程序,从启动开始一直运行,只要有tuple过来 就会触发执行。拓扑: storm的消息流动很像一个拓扑结构。

- **2.** stream是storm的核心概念,一个stream是一个持续的tuple序列,这些tuple被以分布式并行的方式创建和处理。
- **3.** spouts是一个stream的源头,spouts负责从外部系统读取数据,并组装成tuple发射出去,tuple被发射后就开始再topology中传播。
- **4.** bolt是storm中处理数据的核心,storm中所有的数据处理都是在bolt中完成的这里就简单介绍一些概念具体的可以看些详细的教程。

我们接下来开始整合storm和kafka。

从上面的介绍得知storm的spout是负责从外部读取数据的 所以我们需要开发一个KafkaSpout 来作为kafka的消费者和storm的数据接收源。可以看看这个https://github.com/HolmesNL/kafka-spout。我在下面只写一个简单的可供测试。

具体代码:

```
[java] view plain copy print ?
public class KafkaSpout implements IRichSpout {
              private static final Log logger = LogFactory.getLog(KafkaSpout.class);
               */
              private static final long serialVersionUID = -5569857211173547938L;
              private ConsumerConnectorconsumer;
              private Stringtopic;
              public KafkaSpout(String topic) {
                          this.topic = topic;
              @Override
              public void open(Map conf, TopologyContext context,
                          this.collector = collector;
              private static ConsumerConfig createConsumerConfig() {
                          props.put("zookeeper.connect","xx.xx.xx.xx:2181");
                          props.put("group.id","0");
                          //props.put("zookeeper.sync.time.ms", "200");
                          //props.put("auto.commit.interval.ms", "1000");
                          return new ConsumerConfig(props):
              public void close() {
                          // TODOAuto-generated method stub
              @Override
              public void activate() {
                          this.consumer = Consumer.createJavaConsumerConnector(createConsumerConfig());
                          topickMap.put(topic,new Integer(1));
                          \label{limits} \mbox{Map} < \mbox{String, List} < \mbox{KafkaStream} < \mbox{{\it byte}[], byte[]} > > \mbox{streamMap} = \mbox{consumer.createMessageStream} < \mbox{{\it consumer.createMessageStream} < \mbox{{\it consumer.createMessageStream}} < \mbox{{\it consumer.createMessageStream} < \mbox{{\it consumer.createMessageStream}} 
                          KafkaStream<byte[],byte[]>stream = streamMap.get(topic).get(0);
                          ConsumerIterator<byte[],byte[]> it =stream.iterator();
                          while (it.hasNext()) {
                                        String value = newString(it.next().message());
                                        System.out.println("(consumer)-->" + value);
                                         collector.emit(new Values(value), value);
              @Override
              public void deactivate() {
                          // TODOAuto-generated method stub
              private boolean isComplete;
              @Override
              public void nextTuple() {
              @Override
              public void ack(Object msgId) {
```

```
// TODOAuto-generated method stub
     @Override
     public void fail(Object msgId) {
          // TODOAuto-generated method stub
     @Override
     public void declareOutputFields(OutputFieldsDeclarer declarer) {
           declarer.declare(new Fields("KafkaSpout"));
     @Override
     public Map<String, Object> getComponentConfiguration() {
          // TODOAuto-generated method stub
           return null;
public class FileBlots implementsIRichBolt{
      public void prepare(Map stormConf, TopologyContext context,
           this.collector = collector;
     public void execute(Tuple input) {
          String line = input.getString(0);
           for(String str : line.split("\\s+")){
           List a = newArrayList();
           a.add(input);
           this.collector.emit(a,newValues(str));
           this.collector.ack(input);
     public void cleanup() {
      public void declareOutputFields(OutputFieldsDeclarer declarer) {
          declarer.declare(new Fields("words"));
      public Map<String, Object> getComponentConfiguration() {
           // TODOAuto-generated method stub
           return null;
public class WordsCounterBlots implementsIRichBolt{
     Map<String, Integer> counter;
     public void prepare(Map stormConf, TopologyContext context,
           this.collector = collector;
           this.counter =new HashMap<String, Integer>();
     public void execute(Tuple input) {
           String word = input.getString(0);
           Integer integer = this.counter.get(word);
           \textbf{if}(\texttt{integer} \ ! = \textbf{null}) \{
                 integer +=1:
                 this.counter.put(word, integer);
           }else{
                 this.counter.put(word, 1);
```

Topology测试:

至此flume + kafka+storm的整合就写完了。注意 这个是 初始学习阶段做的测试 不可正式用于线上环境,在写本文之时 已经离测试过去了一段时间 所以可能会有些错误 请见谅。



上一篇 kafka Failed to send messages after 3 tries 问题解决

下一篇 jdk6的下载地址

我的同类文章

```
storm (1) kafka (1)
```

• storm 例子 记录

2014-01-10 阅读 632

猜你在找

Storm应用开发系列从入门到精通

hbase入门精讲

Ceph—分布式存储系统的另一个选择

Jmeter性能测试全程实战

移动APP测试基础到进阶





计算机学校排











杏看评论

4楼 zengqingchun 2015-12-26 22:04发表



JedisUtils 这个类是自己写的吧 查api没有这个类

3楼 u010409394 2015-09-24 11:43发表



前辈,本文中的"Worker:处理逻辑的进程,在其中运行着多个Task,每个task 是一组spout/blots的组合。"这句话,描述 的好像不太合理,希望及时更正过来,我qq是826855366

2楼 cepgurugen 2014-12-15 14:12发表



感谢分享, Karfka可以连接到hadoop,DW等非流式数据处理系统。如果只是为了连接到流式处理引擎,需要保证消息队列 系统的稳定。http://www.sodbase.com/news/html/?422.html

1楼 yebai 2014-06-03 20:58发表



弄得我以为是线上系统呢。

您还没有登录,请[登录]或[注册]

*以上用户言论只代表其个人观点,不代表CSDN网站的观点或立场

核心技术类目

全部主题 Hadoop AWS 移动游戏 Java Android iOS Swift 智能硬件 Docker OpenStack VPN Spark ERP IE10 Eclipse CRM JavaScript 数据库 Ubuntu NFC WAP BI HTML5 Spring Apache .NET API HTML SDK IIS Fedora XML LBS Splashtop UML components Windows Mobile Rails QEMU KDE Cassandra FTC coremail OPhone CouchBase 云计算 iOS6 Rackspace Web App SpringSide Compuware 大数据 aptech Perl Tornado Ruby Hibernate ThinkPHP HBase Pure Angular Cloud Foundry Redis Scala Django Bootstrap

公司简介 | 招贤纳士 | 广告服务 | 银行汇款帐号 | 联系方式 | 版权声明 | 法律顾问 | 问题报告 | 合作伙伴 | 论坛反馈

微博客服 webmaster@csdn.net 400-600-2320 | 北京创新乐知信息技术有限公司 版权所有 | 江苏乐知网络技术有限公司 提供商务支持 网站客服 杂志客服

京 ICP 证 09002463 号 | Copyright © 1999-2014, CSDN.NET, All Rights Reserved 😍