Charles的技术博客

BloomFilter原理，实现及优化

2016-12-03 | 后台开发

引言

最近在做性能优化相关的事情，其中涉及到了BloomFilter，于是对BloomFilter总结了下，本文组织结构如下：

- BloomFilter的使用场景
- BloomFilter的原理
- BloomFilter的实现及优化

BloomFilter的使用场景

首先，简单来看下BloomFilter是做什么的？

> A Bloom filter is a space-efficient probabilistic data structure, conceived by Burton Howard Bloom in 1970, that is used to test whether an element is a member of a set. False positive matches are possible, but false negatives are not, thus a Bloom filter has a 100% recall rate. In other words, a query returns either “possibly in set” or “definitely not in set”.

上述描述引自维基百科，特点总结为如下：

- 空间效率高的概率型数据结构，用来检查一个元素是否在一个集合中
- 对于一个元素检测是否存在的调用，BloomFilter会告诉调用者两个结果之一：可能存在或者一定不存在

其次，为什么需要BloomFilter？

常用的数据结构，如hashmap，set，bit array都能用来测试一个元素是否存在于一个集合中，相对于这些数据结构，BloomFilter有什么方面的优势呢？

- 对于hashmap，其本质上是一个指针数组，一个指针的开销是sizeof(void *)，在64bit的系统上是64个bit，如果采用开链法处理冲突的话，又需要额外的指针开销，而对于BloomFilter来讲，返回可能存在的情况中，如果允许有1%的错误率的话，每个元素大约需要10bit的存储空间，整个存储空间的开销大约是hashmap的15%左右（数据来自维基百科）
- 对于set，如果采用hashmap方式实现，情况同上；如果采用平衡树方式实现，一个节点需要一个指针存储数据的位置，两个指针指向其子节点，因此开销相对于hashmap来讲是更多的
- 对于bit array，对于某个元素是否存在，先对元素做hash，取模定位到具体的bit，如果该bit为1，则返回元素存在，如果该bit为0，则返回此元素不存在。可以看出，在返回元素存在的时候，也是会有误判的，如果要获得和BloomFilter相同的误判率，则需要比BloomFilter更大的存储空间

当然，BloomFilter也有它的劣势，如下：

- 相对于hashmap和set，BloomFilter在返回元素可能存在的情况中，有一定的误判率，这时候，调用者在误判的时候，会做一些不必要的工作，而对于hashmap和set，不会存在误判情况
- 对于bit array，BloomFilter在插入和查找元素是否存在时，需要做多次hash，而bit array只需要做一次hash，实际上，bit array可以看做是BloomFilter的一种特殊情况

最后，以一个例子具体描述使用BloomFilter的场景，以及在此场景下，BloomFilter的优势和劣势。

一组元素存在于磁盘中，数据量特别大，应用程序希望在元素不存在的时候尽量不读磁盘，此时，可以在内存中构建这些磁盘数据的BloomFilter，对于一次读数据的情况，分为以下几种情况：

1. 请求的元素不在磁盘中，如果BloomFilter返回不存在，那么应用不需要走读盘逻辑，假设此概率为P1；如果BloomFilter返回可能存在，那么属于误判情况，假设此概率为P2
2. 请求的元素在磁盘中，BloomFilter返回存在，假设此概率为P3

如果使用hashmap或者set的数据结构，情况如下：

1. 请求的数据不在磁盘中，应用不走读盘逻辑，此概率为P1+P2
2. 请求的元素在磁盘中，应用走读盘逻辑，此概率为P3

假设应用不读盘逻辑的开销为C1，走读盘逻辑的开销为C2，那么，BloomFilter和hashmap的开销为

```
Cost(BloomFilter) = P1 * C1 + (P2 + P3) * C2
Cost(HashMap) = (P1 + P2) * C1 + P3 * C2;

Delta = Cost(BloomFilter) - Cost(HashMap)
      = P2 * (C2 - C1)
```

因此，BloomFilter相当于以增加 `P2 * (C2 - C1)` 的时间开销，来获得相对于hashmap而言更少的空间开销。

既然P2是影响BloomFilter性能开销的主要因素，那么BloomFilter设计时如何降低概率P2（即false positive probability）呢？，接下来的BloomFilter的原理将回答这个问题。

BloomFilter的原理

原理

BloomFilter通常采用bit array实现，假设其bit总数为m，初始化时m个bit都被置成0。

BloomFilter中插入一个元素，会使用k个hash函数，来计算出k个在bit array中的位置，然后，将bit array中这些位置的bit都置为1。

以一个例子，来说明添加的过程，这里，假设m=19，k=2，如下：

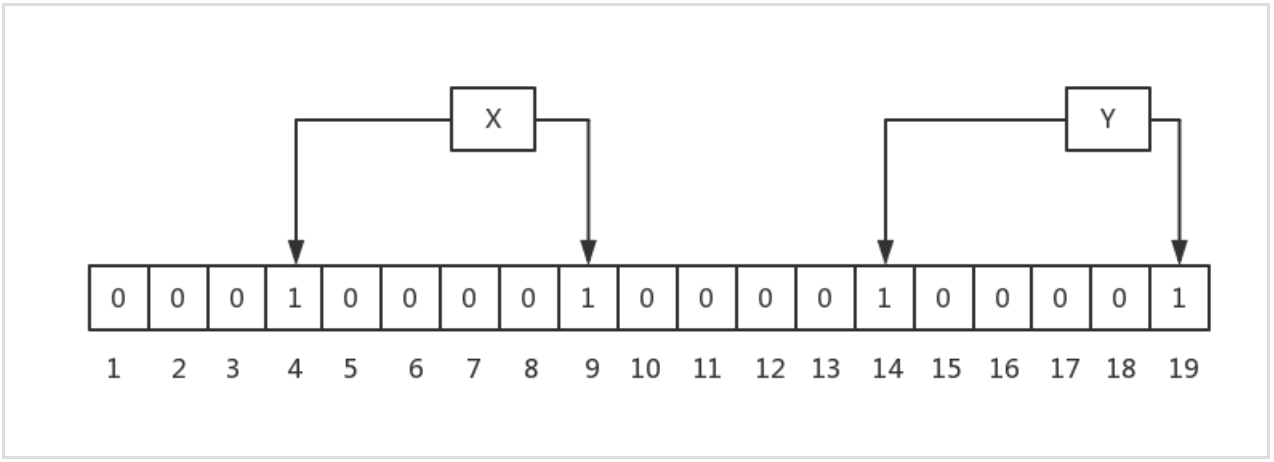

如上图，插入了两个元素，X和Y，X的两次hash取模后的值分别为4,9，因此，4和9位被置成1；

Y的两次hash取模后的值分别为14和19，因此，14和19位被置成1。

BloomFilter中查找一个元素，会使用和插入过程中相同的k个hash函数，取模后，取出每个bit对应的值，如果所有bit都为1，则返回元素可能存在，否则，返回元素不存在。

为什么bit全部为1时，是表示元素可能存在呢？

还是以上图的例子说明，如果要查找的元素是X，k个hash函数计算后，取出的bit都是1，此时，X本身也是存在的；假如，要查找另一个元素Z，其hash计算出来的位置为9,14，此时，BloomFilter认为此元素存在，但是，Z实际上是不存在的，此现象称为false positive。

最后，BloomFilter中不允许有删除操作，因为删除后，可能会造成原来存在的元素返回不存在，这个是不允许的，还是以一个例子说明：

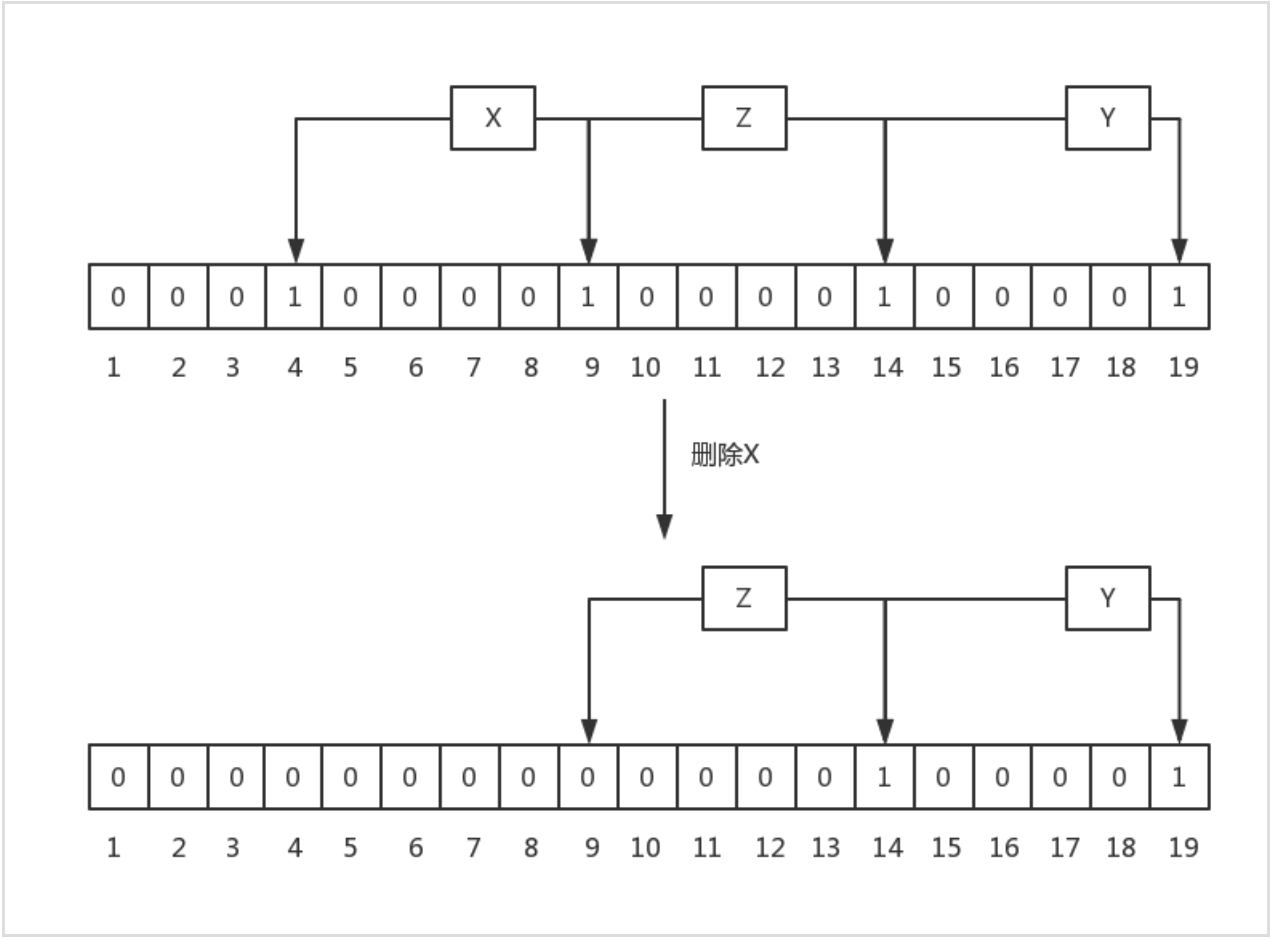

上图中，刚开始时，有元素X，Y和Z，其hash的bit如图中所示，当删除X后，会把bit 4和9置成0，这同时会造成查询Z时，报不存在的问题，这对于BloomFilter来讲是不能容忍的，因为它要么返回绝对不存在，要么返回可能存在。

放到之前的磁盘读数据的例子来讲，如果删除了元素X，导致应用读取Z时也会返回记录不存在，

这是不符合预期的。

BloomFilter中不允许删除的机制会导致其中的无效元素可能会越来越多，即实际已经在磁盘删除中的元素，但在bloomfilter中还认为可能存在，这会造成越来越多的false positive，在实际使用中，一般会废弃原来的BloomFilter，重新构建一个新的BloomFilter。

参数如何取值

在实际使用BloomFilter时，一般会关注false positive probability，因为这和额外开销相关。实际的使用中，期望能给定一个false positive probability和将要插入的元素数量，能计算出分配多少的存储空间较合适。

假设BloomFilter中元素总bit数量为m，插入的元素个数为n，hash函数的个数为k，false positive probability记做p，它们之间有如下关系（具体推导过程请参考维基百科）：

如果需要最小化false positive probability，则k的取值如下

```
1   k = m * ln2 / n;  公式一
```

而p的取值，和m，n又有如下关系

```
1   m = - n * lnp / (ln2) ^ 2 公式二
```

把公式一代入公式二，得出给定n和p，k的取值应该为

```
1   k = -lnp / ln2
```

最后，也同样可以计算出m。

BloomFilter实现及优化

基本版实现

基础的数据结构如下：

```
template<typename T>
class BloomFilter
{
 public:
  BloomFilter(const int32_t n, const double false_positive_p);
  void insert(const T &key);
  bool key_may_match(const T &key);

 private:
  std::vector<char> bits_;
  int32_t k_;
  int32_t m_;
  int32_t n_;
  double p_;
};
```

其中bits_是用vector模拟的bit array，其他对应于BloomFilter原理一节所说的几个参数。

整个BloomFilter包含三个操作：

- 初始化：即上述代码中的构造函数
- 插入：即上述代码中的insert
- 判断是否存在：即上述代码中的key_may_match

初始化

根据BloomFilter原理一节中的方法进行计算，代码如下：

```
template<typename T>
BloomFilter<T>::BloomFilter(const int32_t n, const double false_positive_p)
  : bits_(), k_(0), m_(0), n_(n), p_(false_positive_p)
{
  k_ = static_cast<int32_t>(-std::log(p_) / std::log(2));
  m_ = static_cast<int32_t>(k_ * n * 1.0 / std::log(2));
  bits_.resize((m_ + 7) / 8, 0);
}
```

这里开始实现的时候犯了个低级的错误，一开始用的是 `bits_.reserve` ，导致BloomFilter的false positive probability非常高，原因是reserve方法只分配内存，并不进行初始化。

插入

即设置每个hash函数计算出来的bit为1，代码如下

```
template<typename T>
void BloomFilter<T>::insert(const T &key)
{
  uint32_t hash_val = 0xbc9f1d34;
  for (int i = 0; i < k_; ++i) {
    hash_val = key.hash(hash_val);
    const uint32_t bit_pos = hash_val % m_;
    bits_[bit_pos/8] |= 1 << (bit_pos % 8);
  }
}
```

判断是否存在

即计算每个hash函数对应的bit的值，如果全为1，则返回存在；否则，返回不存在。

```
template<typename T>
bool BloomFilter<T>::key_may_match(const T &key)
{
  uint32_t hash_val = 0xbc9f1d34;
  for (int i = 0; i < k_; ++i) {
    hash_val = key.hash(hash_val);
    const uint32_t bit_pos = hash_val % m_;
    if ((bits_[bit_pos/8] & (1 << (bit_pos % 8))) == 0) {
      return false;
    }
  }
  return true;
}
```

下面进行了一组测试，设置期望的false positive probability为0.1，模拟key从10000增长到100000的场景，观察真实的false positive probability的情况：

```
key_nums_=10000 expected false positive rate=0.1 real false positive rate=0
key_nums_=20000 expected false positive rate=0.1 real false positive rate=0
key_nums_=30000 expected false positive rate=0.1 real false positive rate=0
key_nums_=40000 expected false positive rate=0.1 real false positive rate=0
key_nums_=50000 expected false positive rate=0.1 real false positive rate=0
```

```
key_nums_=60000 expected false positive rate=0.1 real false positive rate=0
key_nums_=70000 expected false positive rate=0.1 real false positive rate=0
key_nums_=80000 expected false positive rate=0.1 real false positive rate=0
key_nums_=90000 expected false positive rate=0.1 real false positive rate=0
key_nums_=100000 expected false positive rate=0.1 real false positive rate=
```

由于实现的时候，会对k进行取整，根据取整后的结果(k=3)，计算出来的理论值是0.1250，可以，看出实际测出来的值和理论值差别不大。

优化

前面实现的版本中，多次调用了hash_func函数，这对于计算比较长的字符串的hash的开销是比较大的，为了模拟这种场景，插入1000w行的数据，使用perf top来抓取其性能数据，结果如下：

```
Samples: 221K of event 'cycles:pp', Event count (approx.): 173824984579
  Children      Self  Command      Shared Object        Symbol
+   88.35%    19.02%  bloomfilter  bloomfilter          [.] PerfTestSuite::gen_keys
+   88.31%     0.00%  bloomfilter  bloomfilter          [.] _start
+   88.31%     0.00%  bloomfilter  libc-2.23.so         [.] __libc_start_main
+   88.31%     0.00%  bloomfilter  bloomfilter          [.] main
+   88.31%     0.00%  bloomfilter  bloomfilter          [.] test_perf
+   54.77%    29.54%  bloomfilter  bloomfilter          [.] gen_random_string[abi:cxx11]
+   29.11%     4.47%  bloomfilter  libc-2.23.so         [.] rand
+   28.75%    14.81%  bloomfilter  libc-2.23.so         [.] __random
+   13.95%    13.94%  bloomfilter  libc-2.23.so         [.] __random_r
+   13.00%    12.99%  bloomfilter  bloomfilter          [.] hash_func
+    4.57%     0.00%  bloomfilter  [unknown]            [.] 0x00007ffc835ee9a0
+    2.14%     0.00%  bloomfilter  [unknown]            [.] 0x00007ffc835ee980
```

如上图，除了生成数据的函数外，占用CPU最高的就属于hash_func了，占用了13%的CPU。

分析之前的代码可以知道，insert和key_may_match时，都会多次调用hash_func，这个开销是比较大的。

leveldb和维基百科中都有提到，根据之前的研究，可以采用两次hash的方式来替代上述的多次的计算，基本的思路如下：

```
template<typename T>
void BloomFilter<T>::insert2(const T &key)
{
  uint32_t hash_val = key.hash(0xbc9f1d34);
  const uint32_t delta = (hash_val >> 17) | (hash_val << 15);
  for (int i = 0; i < k_; ++i) {
    const uint32_t bit_pos = hash_val % m_;
    bits_[bit_pos/8] |= 1 << (bit_pos % 8);
```

```
9       hash_val += delta;
10    }
11  }
```

即先用通常的hash函数计算一次，然后，使用移位操作计算一次，最后，k次计算的时候，不断累加两次的结果。

经过优化后，性能数据图如下：

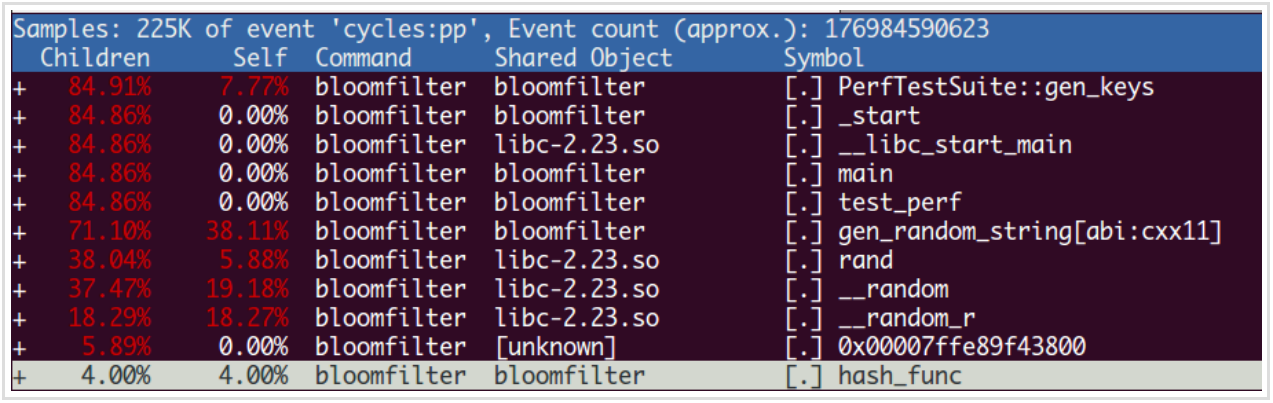

```
Samples: 225K of event 'cycles:pp', Event count (approx.): 176984590623
  Children      Self  Command      Shared Object       Symbol
+   84.91%     7.77%  bloomfilter  bloomfilter         [.] PerfTestSuite::gen_keys
+   84.86%     0.00%  bloomfilter  bloomfilter         [.] _start
+   84.86%     0.00%  bloomfilter  libc-2.23.so        [.] __libc_start_main
+   84.86%     0.00%  bloomfilter  bloomfilter         [.] main
+   84.86%     0.00%  bloomfilter  bloomfilter         [.] test_perf
+   71.10%    38.11%  bloomfilter  bloomfilter         [.] gen_random_string[abi:cxx11]
+   38.04%     5.88%  bloomfilter  libc-2.23.so        [.] rand
+   37.47%    19.18%  bloomfilter  libc-2.23.so        [.] __random
+   18.29%    18.27%  bloomfilter  libc-2.23.so        [.] __random_r
+    5.89%     0.00%  bloomfilter  [unknown]           [.] 0x00007ffe89f43800
+    4.00%     4.00%  bloomfilter  bloomfilter         [.] hash_func
```

和之前性能图对比发现，hash_func的CPU使用率已经减少到4%了。

对比完性能之后，我们还需要对比hash函数按照如此优化后，false positive probability的变化情况：

```
1   before_opt
2   key_nums_=10000 expected false positive rate=0.1 real false positive rate=0
3   key_nums_=20000 expected false positive rate=0.1 real false positive rate=0
4   key_nums_=30000 expected false positive rate=0.1 real false positive rate=0
5   key_nums_=40000 expected false positive rate=0.1 real false positive rate=0
6   key_nums_=50000 expected false positive rate=0.1 real false positive rate=0
7   key_nums_=60000 expected false positive rate=0.1 real false positive rate=0
8   key_nums_=70000 expected false positive rate=0.1 real false positive rate=0
9   key_nums_=80000 expected false positive rate=0.1 real false positive rate=0
10  key_nums_=90000 expected false positive rate=0.1 real false positive rate=0
11  key_nums_=100000 expected false positive rate=0.1 real false positive rate=(
12  after_opt
13  key_nums_=10000 expected false positive rate=0.1 real false positive rate=0
14  key_nums_=20000 expected false positive rate=0.1 real false positive rate=0
15  key_nums_=30000 expected false positive rate=0.1 real false positive rate=0
16  key_nums_=40000 expected false positive rate=0.1 real false positive rate=0
17  key_nums_=50000 expected false positive rate=0.1 real false positive rate=0
18  key_nums_=60000 expected false positive rate=0.1 real false positive rate=0
19  key_nums_=70000 expected false positive rate=0.1 real false positive rate=0
```

```
20  key_nums_=80000 expected false positive rate=0.1 real false positive rate=0
21  key_nums_=90000 expected false positive rate=0.1 real false positive rate=0
22  key_nums_=100000 expected false positive rate=0.1 real false positive rate=
```

优化后，最大的false positive probability增长了2%左右，这个可以增加k来弥补，因为，优化后的hash算法，在k增长时，带来的开销相对来讲不大。

备注，本节采用perf抓取性能数据图，命令如下

```
1  sudo perf record -a --call-graph dwarf -p 9125 sleep 60
2  sudo perf report -g graph
```

本文的代码在bloomfilter.cpp，使用文档在ReadMe。

PS:
本博客更新会在第一时间推送到微信公众号，欢迎大家关注。

参考文献

- bloomfilter wikipage
- Less Hashing, Same Performance:Building a Better Bloom Filter

#BloomFilter #算法

consistent hash原理，优化及实现 NewSQL究竟新在哪里？

喜欢

3条评论

louis813

hi, 博主的 atom 输出中的域名 (yoursite.com) 已经失效，并为指向现在的域名 (oserror.com)

2016年12月7日 回复 顶 转发

xx

http://www.yebangyu.org/blog/2016/01/23/insidethebloomfilter/

2016年12月27日 回复 顶 转发

Charles0429

回复 xx: 赞

1月2日 回复 顶 转发 举报

大胡子圣诞老人 帐号管理

说点什么吧...

发布

Charles的技术博客正在使用多说